BÁO CÁO THỰC HÀNH

KHAI PHÁ DỮ LIỆU

Áp dụng KNN, K-Means, Naive Bayes và Decision Tree trên hai bộ dữ liệu UCI

Dataset 1: Predict Students' Dropout and Academic Success (UCI #697)
Dataset 2: Individual Household Electric Power Consumption (UCI #235)

Sinh viên thực hiện: Hoàng Văn Huynh
MSSV: B23DCCC086

Ngày: 08/10/2026

1. Mục tiêu và quy trình thực hiện

Chọn 2 trong 4 dataset: **#697 Students' Dropout** (dữ liệu bảng, có sẵn nhãn 3 lớp) và **#235 Household Power** (2 triệu bản ghi chuỗi thời gian, nhiệm vụ gốc gồm phân cụm). Trên mỗi dataset: phân tích thống kê, áp dụng **KNN, Naive Bayes, Decision Tree** (phân lớp) và **K-Means** (phân cụm).

Bước	Nội dung
1. Thu thập	Tải dữ liệu gốc từ UCI Machine Learning Repository
2. Thống kê mô tả	Kích thước, giá trị thiếu, mean / std / min / max / tứ phân vị, skewness, kurtosis, phân bố, tương quan
3. Tiền xử lý	Xử lý thiếu, One-Hot biến danh mục, chuẩn hóa StandardScaler, tạo đặc trưng / nhãn, chia train–test
4. Mô hình	KNN, Gaussian Naive Bayes, Decision Tree (GridSearchCV 5-fold, tiêu chí macro-F1); K-Means (k-means++)
5. Đánh giá	Phân lớp: Accuracy, macro-F1, F1 từng lớp, ma trận nhầm lẫn. Phân cụm: Elbow, Silhouette, ARI / NMI

- **KNN:** gán nhãn theo đa số *k* láng giềng gần nhất (khoảng cách Euclid) → cần chuẩn hóa.
- **Naive Bayes:** định lý Bayes, giả định các đặc trưng độc lập và phân phối chuẩn trong mỗi lớp.
- **Decision Tree:** chia dữ liệu theo ngưỡng làm giảm Gini nhiều nhất; dễ diễn giải.
- **K-Means:** chia K cụm, cực tiểu tổng bình phương khoảng cách tới tâm cụm; lặp *gán điểm → cập nhật tâm*.

Dữ liệu mất cân bằng lớp nên mô hình được chọn theo **macro-F1** (trung bình F1 các lớp).

2. Dataset 1 – Students' Dropout and Academic Success (UCI #697)

2.1 Dữ liệu và thống kê mô tả

4.424 sinh viên một trường đại học Bồ Đào Nha, 36 đặc trưng (nhân khẩu học, tuyển sinh, tài chính, kết quả học tập HK1–HK2, kinh tế vĩ mô) và nhãn `Target`: **Dropout / Enrolled / Graduate**. Nhiều cột số nguyên thực chất là **mã danh mục** (Course, nghề nghiệp cha mẹ…).

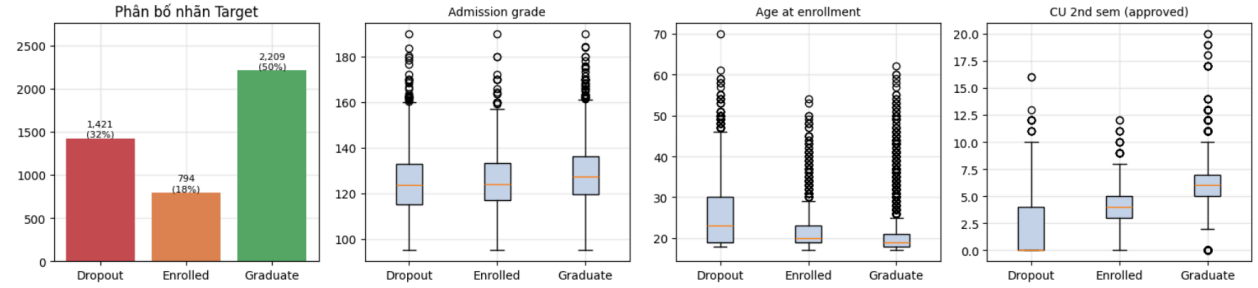
```
Kích thước: 4,424 dòng × 37 cột | Giá trị thiếu: 0 | Dòng trùng: 0
```

Hình 1. 2.1 Dữ liệu và thống kê mô tả – ảnh chụp màn hình kết quả chạy chương trình

Thống kê mô tả các biến số chính

	n	mean	std	min	25%	median	75%	max	skew	kurtosis	missing
Admission grade	4,424.000	126.978	14.482	95.000	117.900	126.100	134.800	190.000	0.531	0.663	0
Previous qualification (grade)	4,424.000	132.613	13.188	95.000	125.000	133.100	140.000	190.000	0.313	0.968	0
Age at enrollment	4,424.000	23.265	7.588	17.000	19.000	20.000	25.000	70.000	2.055	4.127	0
CU 1st sem (credited)	4,424.000	0.710	2.361	0.000	0.000	0.000	0.000	20.000	4.169	19.206	0
CU 1st sem (approved)	4,424.000	4.707	3.094	0.000	3.000	5.000	6.000	26.000	0.766	3.097	0
CU 1st sem (grade)	4,424.000	10.641	4.844	0.000	11.000	12.286	13.400	18.875	-1.568	0.908	0
CU 2nd sem (approved)	4,424.000	4.436	3.015	0.000	2.000	5.000	6.000	20.000	0.306	0.845	0
CU 2nd sem (grade)	4,424.000	10.230	5.211	0.000	10.750	12.200	13.333	18.571	-1.314	0.067	0
Unemployment rate	4,424.000	11.566	2.664	7.600	9.400	11.100	13.900	16.200	0.212	-0.996	0

Hình 2. 2.1 Dữ liệu và thống kê mô tả – ảnh chụp màn hình kết quả chạy chương trình



Hình 3. 2.1 Dữ liệu và thống kê mô tả – ảnh chụp màn hình kết quả chạy chương trình

Trung bình theo lớp và tương quan với Target (Dropout=0, Enrolled=1, Graduate=2)

Target	Dropout	Enrolled	Graduate	r với Target
CU 2nd sem (approved)	1.940	4.058	6.177	0.624
CU 2nd sem (grade)	5.899	11.117	12.697	0.567
CU 1st sem (approved)	2.552	4.319	6.232	0.529
CU 1st sem (grade)	7.257	11.125	12.644	0.485
Tuition fees up to date	0.678	0.947	0.987	0.410
Scholarship holder	0.094	0.164	0.378	0.298
Age at enrollment	26.069	22.369	21.784	-0.243
Debtor	0.220	0.113	0.046	-0.241

Hình 4. 2.1 Dữ liệu và thống kê mô tả – ảnh chụp màn hình kết quả chạy chương trình

Nhận xét: dữ liệu sạch (không thiếu, không trùng). Nhãn **mất cân bằng**: Graduate 50%, Dropout 32%, Enrolled chỉ 18%. Tuổi nhập học lệch phải mạnh (skew 2,06; median 20, max 70); điểm HK1/HK2 lệch trái (median ≈ 12,2 nhưng mean ≈ 10,4) do một khối sinh viên điểm 0; các biến *credited* hầu hết bằng 0 (kurtosis ≈ 19). Biến liên quan mạnh nhất tới Target là **số học phần đạt HK2** (r = 0,62; Dropout TB 1,9 so với Graduate 6,2), điểm HK2, số học phần đạt HK1 và **đóng học phí đúng hạn** (r = 0,41). Điểm đầu vào khác biệt ít giữa các lớp. Lớp Enrolled nằm giữa hai lớp kia ở hầu hết các biến → khó phân loại nhất.

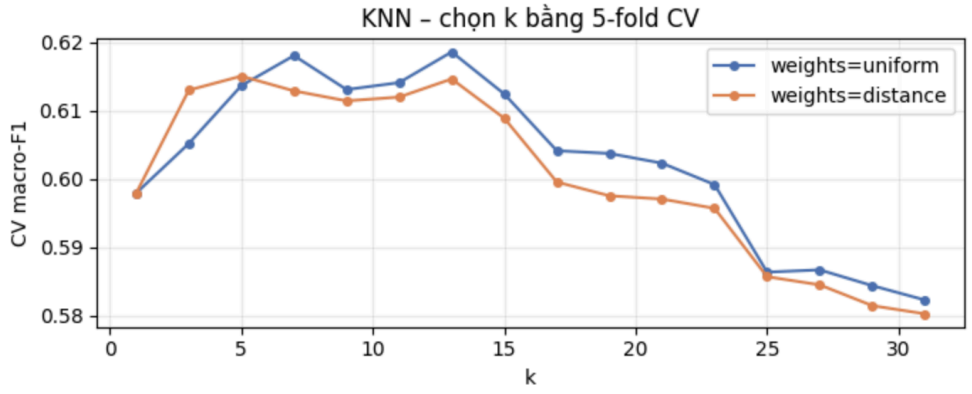
2.2 Tiền xử lý

- **One-Hot** 9 biến mã danh mục; **StandardScaler** các biến số và nhị phân còn lại (đặt trong `Pipeline` để tránh rò rỉ dữ liệu).
- Chia **80% train / 20% test, stratified** theo Target (theo khuyến nghị của tác giả dataset).
- Tìm siêu tham số bằng GridSearchCV, StratifiedKFold 5-fold, tiêu chí macro-F1.

```
Train: 3,539 mẫu | Test: 885 mẫu | Số đặc trưng sau One-Hot: 236
```

Hình 5. 2.2 Tiền xử lý – ảnh chụp màn hình kết quả chạy chương trình

2.3 Phân lớp: KNN, Naive Bayes, Decision Tree

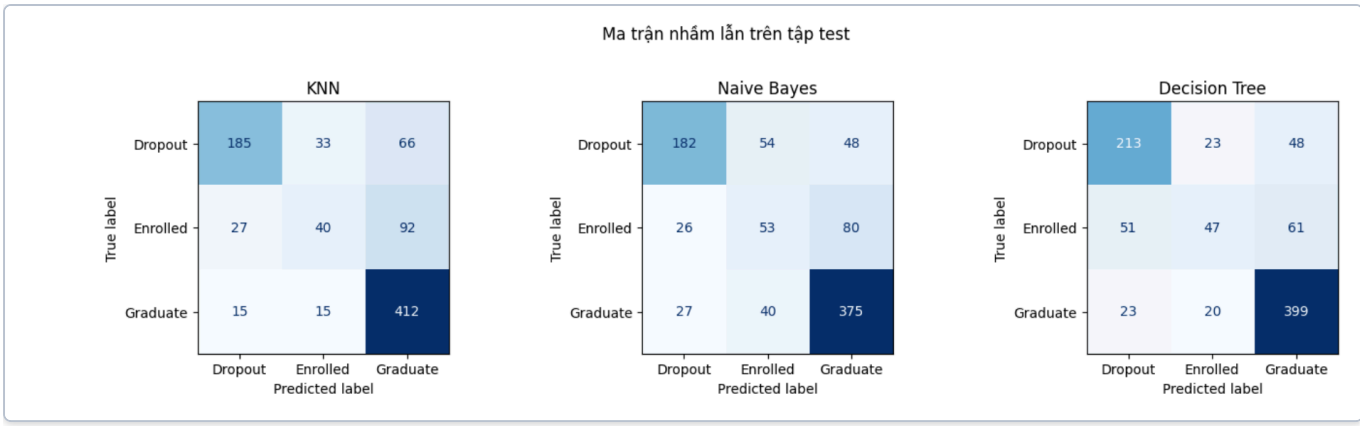


Hình 6. 2.3 Phân lớp: KNN, Naive Bayes, Decision Tree – ảnh chụp màn hình kết quả chạy chương trình

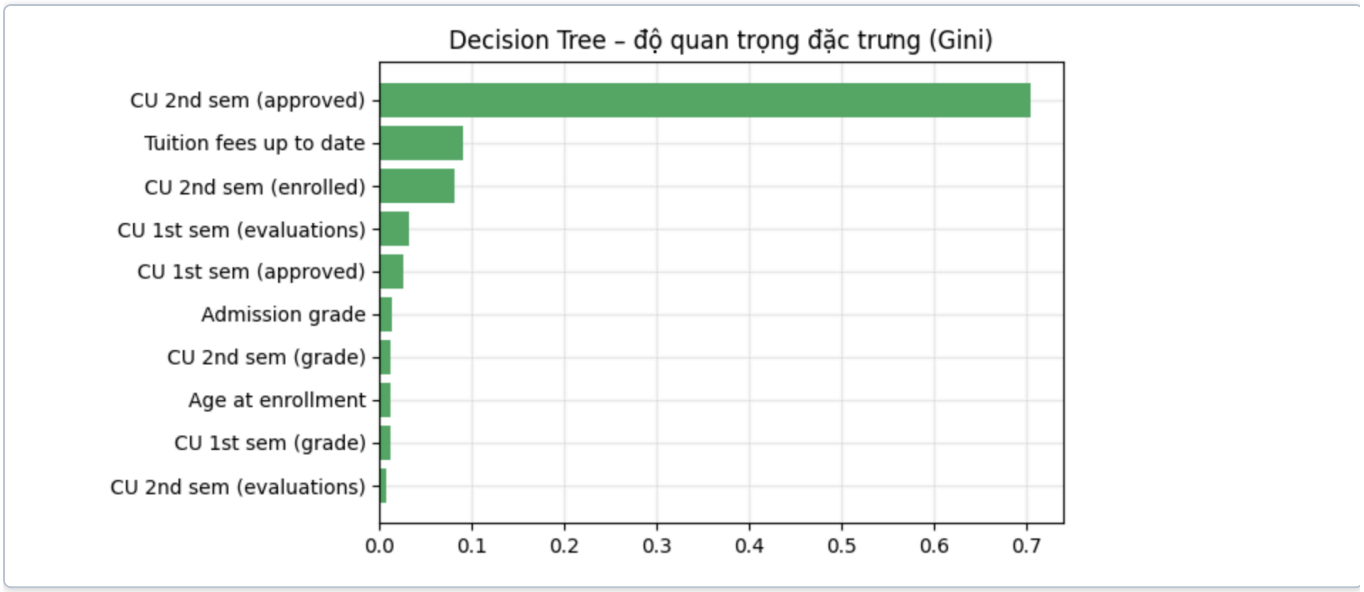
Kết quả trên tập test (tham số chọn bằng GridSearchCV trên tập train)

Mô hình	Tham số tốt nhất	CV macro-F1	Accuracy	macro-F1	F1 Dropout	F1 Enrolled	F1 Graduate
KNN	{'n_neighbors': 13, 'weights': 'uniform'}	0.619	0.720	0.621	0.724	0.324	0.814
Naive Bayes	{'var_smoothing': 0.1}	0.622	0.689	0.614	0.701	0.346	0.794
Decision Tree	{'max_depth': 8, 'min_samples_leaf': 50}	0.676	0.745	0.655	0.746	0.378	0.840

Hình 7. 2.3 Phân lớp: KNN, Naive Bayes, Decision Tree – ảnh chụp màn hình kết quả chạy chương trình



Hình 8. 2.3 Phân lớp: KNN, Naive Bayes, Decision Tree – ảnh chụp màn hình kết quả chạy chương trình



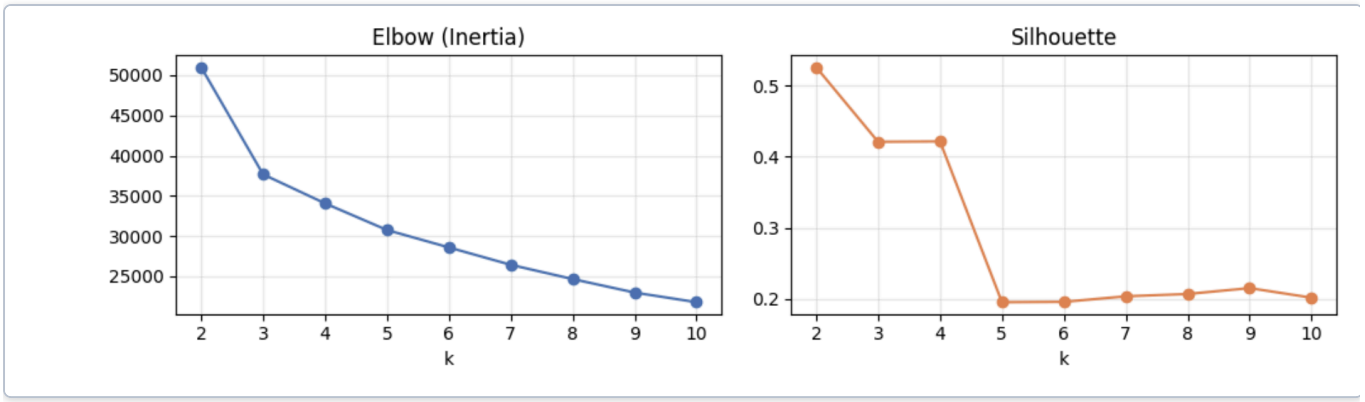
Hình 9. 2.3 Phân lớp: KNN, Naive Bayes, Decision Tree – ảnh chụp màn hình kết quả chạy chương trình

Nhận xét:

- **Decision Tree tốt nhất** (accuracy 0,745; macro-F1 0,655; depth 8, lá ≥ 50 mẫu chống overfitting). Đặc trưng quan trọng nhất là số học phần đạt HK2 (≈ 70%), sau đó là đóng học phí đúng hạn và số học phần đăng ký HK2.
- **KNN** (k = 13): accuracy 0,720; macro-F1 0,621. F1 thấp tại k = 1, cao nhất ở k ≈ 7–13 rồi giảm khi k quá lớn. 236 chiều sau One-Hot làm khoảng cách kém phân biệt.
- **Naive Bayes** kém nhất (accuracy 0,689; macro-F1 0,614) vì các biến HK1–HK2 tương quan mạnh, vi phạm giả định độc lập. Cần `var_smoothing` = 0,1 do các cột One-Hot gần như hằng số trong từng lớp.
- Cả ba mô hình đều yếu ở lớp **Enrolled** (F1 0,32–0,38), lớp thiểu số nằm giữa Dropout và Graduate.

2.4 Phân cụm K-Means

Chỉ dùng 15 biến số có ý nghĩa khoảng cách (điểm đầu vào, tuổi, 12 biến kết quả học tập HK1–HK2), chuẩn hóa z-score; **không dùng nhãn**. Nhãn chỉ dùng sau để đánh giá (ARI, NMI).



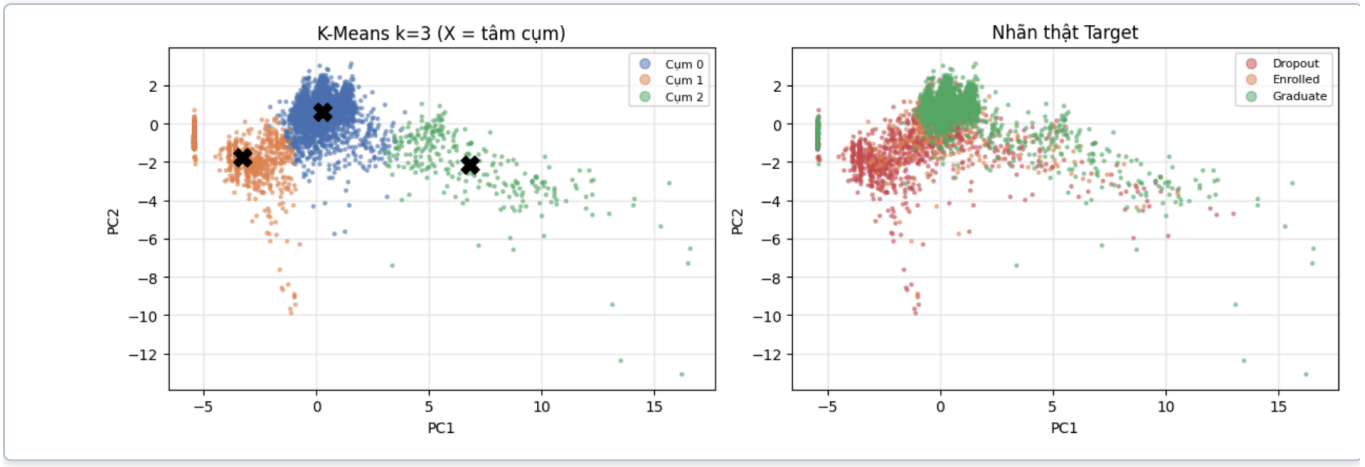
Hình 10. 2.4 Phân cụm K-Means – ảnh chụp màn hình kết quả chạy chương trình

k	2	3	4	5	6	7	8	9	10
Inertia	50,984.161	37,671.125	34,071.115	30,758.842	28,594.553	26,434.314	24,664.035	22,988.083	21,789.082
Silhouette	0.526	0.421	0.421	0.196	0.196	0.204	0.207	0.215	0.202

Hình 11. 2.4 Phân cụm K-Means – ảnh chụp màn hình kết quả chạy chương trình

```
K = 3: Silhouette = 0.421 | ARI = 0.145 | NMI = 0.154
```

Hình 12. 2.4 Phân cụm K-Means – ảnh chụp màn hình kết quả chạy chương trình



Hình 13. 2.4 Phân cụm K-Means – ảnh chụp màn hình kết quả chạy chương trình

Đặc điểm từng cụm (trung bình) và tỉ lệ % Target trong cụm

Cụm	Age at enrollment	CU 1st sem (credited)	CU 2nd sem (enrolled)	CU 2nd sem (approved)	CU 2nd sem (grade)	Dropout (%)	Enrolled (%)	Graduate (%)	Số SV
0	22.182	0.230	6.257	5.074	12.462	20.421	20.571	59.008	3325
1	25.845	0.022	4.397	0.077	0.537	81.993	8.884	9.124	833
2	28.722	8.865	11.662	10.113	12.687	22.180	13.534	64.286	266

Hình 14. 2.4 Phân cụm K-Means – ảnh chụp màn hình kết quả chạy chương trình

Nhận xét: Elbow gãy rõ tại k = 3, silhouette 0,421 → chọn **k = 3**. K-Means *tự tìm ra* nhóm **thất bại học tập** (cụm 1, 833 SV: gần như không đạt học phần nào, **82% là Dropout**), nhóm **học bình thường** (cụm 0, 3.325 SV, 59% Graduate) và nhóm **chuyển tiếp / văn bằng 2** (cụm 2, 266 SV: nhiều học phần được công

nhận, tuổi TB 28,7). Tuy vậy ARI = 0,145 thấp: cụm 0 trộn lẫn cả 3 lớp, Enrolled không tách thành cụm riêng → K-Means hữu ích để khám phá nhưng không thay được mô hình phân lớp.

3. Dataset 2 – Individual Household Electric Power Consumption (UCI #235)

3.1 Dữ liệu và thống kê mô tả

Điện năng của một hộ gia đình ở Sceaux (Pháp), **mỗi phút một bản ghi** từ 12/2006 đến 11/2010. Biến: Global_active_power (GAP, kW), Global_reactive_power (kW), Voltage (V), Global_intensity (A), Sub_metering_1/2/3 (Wh: bếp / giặt / nóng lạnh + điều hòa). Tạo thêm `Sub_metering_rest = GAP×1000/60 − S1 − S2 − S3` (thiết bị khác). Dataset **không có nhãn**.

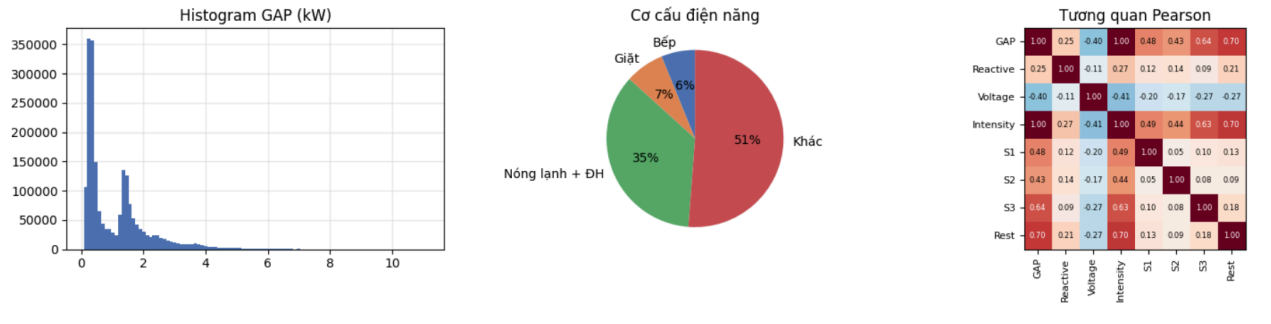
```
Kích thước: 2,075,259 dòng × 7 biến | 16/12/2006 → 26/11/2010
Dòng thiếu giá trị: 25,979 (1.25%), nằm trong 82 ngày
```

Hình 15. 3.1 Dữ liệu và thống kê mô tả – ảnh chụp màn hình kết quả chạy chương trình

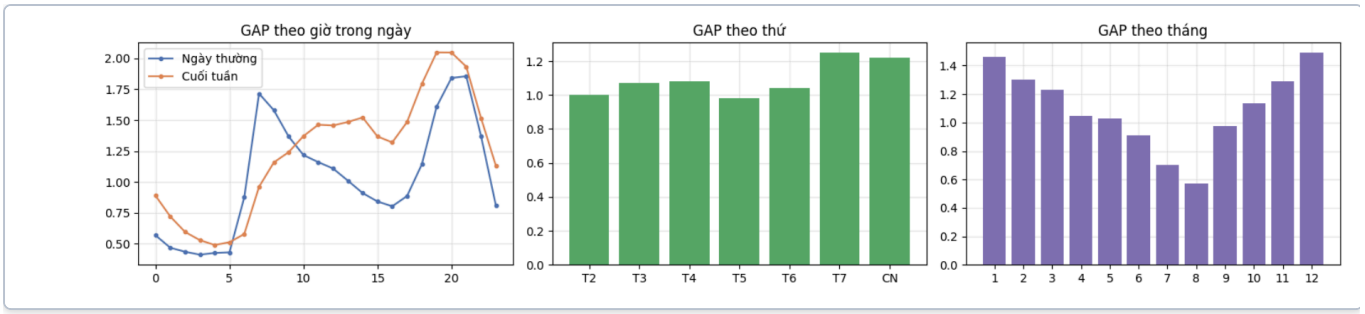
Thống kê mô tả (dữ liệu theo phút)

	n	mean	std	min	25%	median	75%	max	skew	kurtosis	missing
Global_active_power	2,049,280.000	1.092	1.057	0.076	0.308	0.602	1.528	11.122	1.786	4.219	25979
Global_reactive_power	2,049,280.000	0.124	0.113	0.000	0.048	0.100	0.194	1.390	1.262	2.606	25979
Voltage	2,049,280.000	240.840	3.240	223.200	238.990	241.010	242.890	254.150	-0.327	0.725	25979
Global_intensity	2,049,280.000	4.628	4.444	0.200	1.400	2.600	6.400	48.400	1.849	4.601	25979
Sub_metering_1	2,049,280.000	1.122	6.153	0.000	0.000	0.000	0.000	88.000	5.945	35.643	25979
Sub_metering_2	2,049,280.000	1.299	5.822	0.000	0.000	0.000	1.000	80.000	7.091	57.907	25979
Sub_metering_3	2,049,280.000	6.458	8.437	0.000	0.000	1.000	17.000	31.000	0.725	-1.282	25979
Sub_metering_rest	2,049,280.000	9.315	9.586	-2.400	3.800	5.500	10.367	124.833	2.487	7.911	25979

Hình 16. 3.1 Dữ liệu và thống kê mô tả – ảnh chụp màn hình kết quả chạy chương trình



Hình 17. 3.1 Dữ liệu và thống kê mô tả – ảnh chụp màn hình kết quả chạy chương trình



Hình 18. 3.1 Dữ liệu và thống kê mô tả – ảnh chụp màn hình kết quả chạy chương trình

Nhận xét: 1,25% số dòng bị thiếu, tập trung thành khối nhiều ngày liền. GAP **lệch phải** (mean 1,09 > median 0,60 kW; skew 1,79) và có **hai đỉnh** (≈ 0,3 kW tải nền, ≈ 1,4 kW khi có thiết bị lớn). Nóng lạnh + điều hòa chiếm 36% điện năng; thiết bị không đo riêng chiếm 51%. **Global_intensity tương quan r = 1,00 với GAP** (P ≈ U·I) → trùng thông tin; Voltage tương quan âm (−0,40) do sụt áp khi tải lớn. Tiêu thụ có **tính chu kỳ** rõ: ngày thường có đỉnh 7h và 20–21h, cuối tuần tải cao cả ngày; cao vào mùa đông (tháng 12: 1,48 kW), thấp nhất tháng 8 (0,57 kW).

3.2 Tiền xử lý và tạo bài toán phân lớp

- Bỏ các phút thiếu, **gộp theo giờ** (≈ 34 nghìn bản ghi) để giảm nhiễu và giúp KNN khả thi.
- **Nhãn** `Mức tải` của mỗi giờ: Thấp / Trung bình / Cao theo tam phân vị GAP, tính trên tập train.
- **Đặc trưng:** hour, dayofweek, month, is_weekend, Voltage, Global_reactive_power, `lag1` (GAP giờ trước). **Loại** Global_intensity và Sub_metering cùng giờ vì gần như suy ra trực tiếp nhãn (rò rỉ).
- **Chia theo thời gian:** 80% đầu train, 20% cuối test; CV bằng `TimeSeriesSplit`.

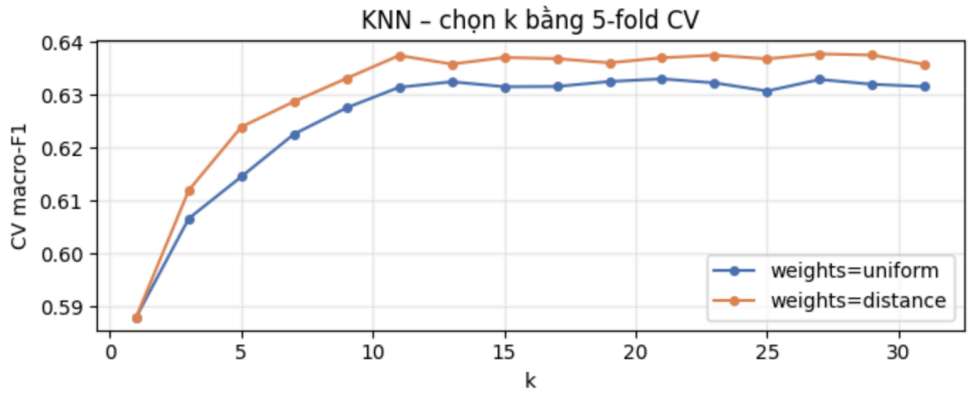
```
Số giờ: 34,159 | Ngưỡng: Thấp ≤ 0.396 kW < Trung bình ≤ 1.395 kW < Cao
Train: 16/12/2006 → 05/02/2010 (27,327 giờ) | Test: 05/02/2010 → 26/11/2010 (6,832 giờ)
```

Hình 19. 3.2 Tiền xử lý và tạo bài toán phân lớp – ảnh chụp màn hình kết quả chạy chương trình

Mức tải	Thấp	Trung bình	Cao
Train (%)	33.333	33.333	33.333
Test (%)	28.908	40.354	30.738

Hình 20. 3.2 Tiền xử lý và tạo bài toán phân lớp – ảnh chụp màn hình kết quả chạy chương trình

3.3 Phân lớp: KNN, Naive Bayes, Decision Tree

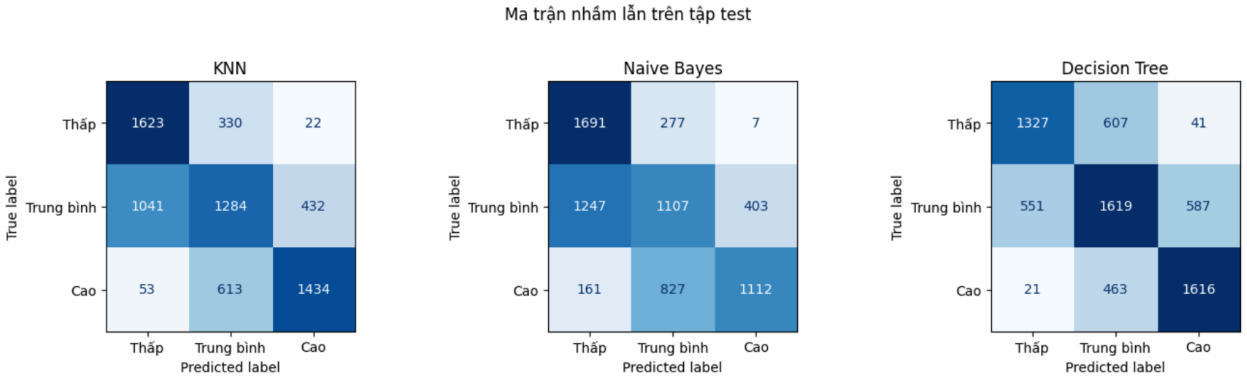


Hình 21. 3.3 Phân lớp: KNN, Naive Bayes, Decision Tree – ảnh chụp màn hình kết quả chạy chương trình

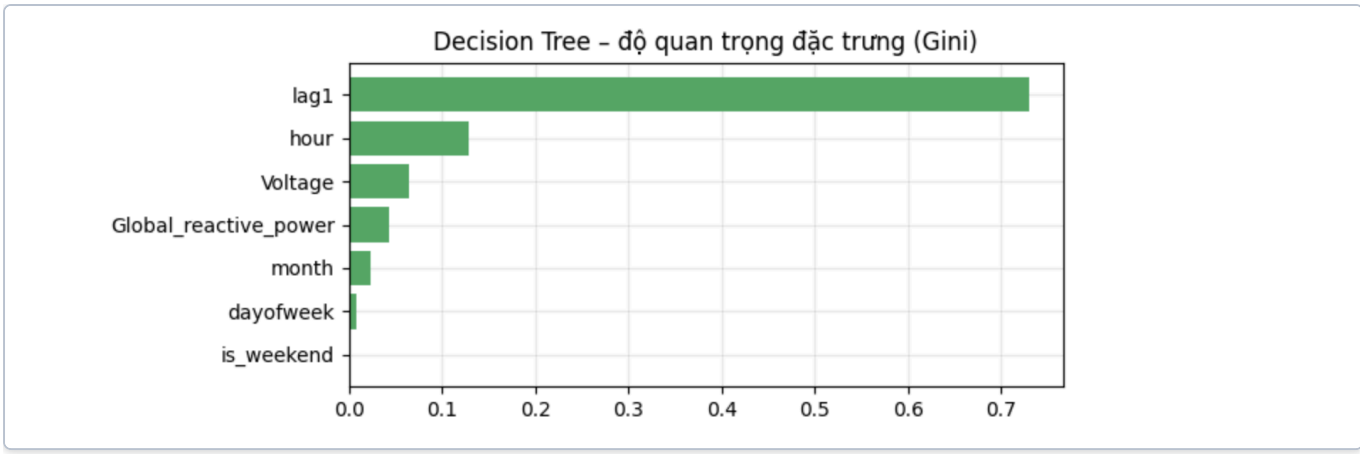
Kết quả trên tập test (tham số chọn bằng GridSearchCV trên tập train)

Mô hình	Tham số tốt nhất	CV macro-F1	Accuracy	macro-F1	F1 Thấp	F1 Trung bình	F1 Cao
KNN	{'n_neighbors': 27, 'weights': 'distance'}	0.638	0.635	0.642	0.692	0.515	0.719
Naive Bayes	{'var_smoothing': 0.0001}	0.596	0.572	0.575	0.667	0.446	0.614
Decision Tree	{'max_depth': 8, 'min_samples_leaf': 10}	0.693	0.668	0.675	0.685	0.595	0.744

Hình 22. 3.3 Phân lớp: KNN, Naive Bayes, Decision Tree – ảnh chụp màn hình kết quả chạy chương trình



Hình 23. 3.3 Phân lớp: KNN, Naive Bayes, Decision Tree – ảnh chụp màn hình kết quả chạy chương trình



Hình 24. 3.3 Phân lớp: KNN, Naive Bayes, Decision Tree – ảnh chụp màn hình kết quả chạy chương trình

Nhận xét:

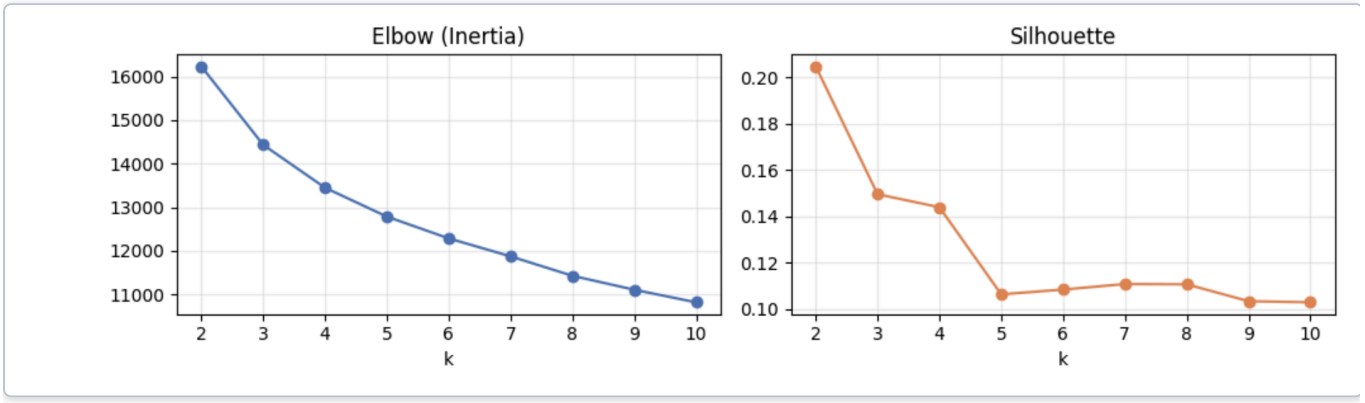
- **Decision Tree tốt nhất** (accuracy 0,668; macro-F1 0,675). `lag1` chiếm ≈ 73% độ quan trọng (quán tính của phụ tải), sau đó là `hour` (≈ 13%).
- **KNN** (k = 27, weights = distance): accuracy 0,635; macro-F1 0,642. k lớn vì dữ liệu nhiễu.
- **Naive Bayes** kém nhất (accuracy 0,572): `lag1` lệch phải, không phân phối chuẩn; quan hệ của `hour` với tải không đơn điệu (hai đỉnh sáng/tối).
- Lớp **Trung bình** khó nhất. Điểm thấp hơn #697 vì nhãn tạo bằng ngưỡng cứng và tập test (02–11/2010) **lệch mùa** so với train (Trung bình chiếm 40%). Kết quả vẫn **gấp đôi đoán ngẫu nhiên** (0,33).

3.4 Phân cụm K-Means – các kiểu ngày tiêu thụ điện

Mỗi **ngày** là một vector 24 chiều (GAP trung bình từng giờ); chỉ giữ ngày đủ 24 giờ. Không chuẩn hóa vì cùng đơn vị kW.

```
Số ngày đủ 24 giờ: 1,417
```

Hình 25. 3.4 Phân cụm K-Means – các kiểu ngày tiêu thụ điện – ảnh chụp màn hình kết quả chạy chương trình



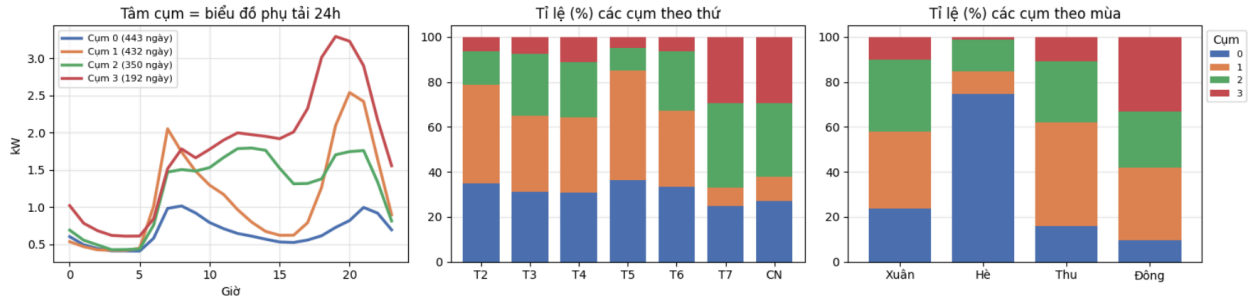
Hình 26. 3.4 Phân cụm K-Means – các kiểu ngày tiêu thụ điện – ảnh chụp màn hình kết quả chạy chương trình

k	2	3	4	5	6	7	8	9	10
Inertia	16,233.597	14,434.030	13,449.010	12,785.468	12,285.571	11,873.252	11,427.090	11,107.041	10,818.112
Silhouette	0.205	0.150	0.144	0.106	0.108	0.111	0.111	0.103	0.103

Hình 27. 3.4 Phân cụm K-Means – các kiểu ngày tiêu thụ điện – ảnh chụp màn hình kết quả chạy chương trình

```
K = 4: Silhouette = 0.144
```

Hình 28. 3.4 Phân cụm K-Means – các kiểu ngày tiêu thụ điện – ảnh chụp màn hình kết quả chạy chương trình



Hình 29. 3.4 Phân cụm K-Means – các kiểu ngày tiêu thụ điện – ảnh chụp màn hình kết quả chạy chương trình

Đặc điểm từng cụm

	Số ngày	GAP TB (kW)	GAP đỉnh (kW)	Giờ đỉnh	kWh/ngày	% cuối tuần
0	443	0.665	1.015	8	15.962	23.476
1	432	1.116	2.540	20	26.791	8.796
2	350	1.237	1.794	13	29.678	40.000
3	192	1.756	3.295	19	42.150	61.458

Hình 30. 3.4 Phân cụm K-Means – các kiểu ngày tiêu thụ điện – ảnh chụp màn hình kết quả chạy chương trình

Nhận xét: không có khuỷu rõ, silhouette thấp (0,10–0,21) vì các kiểu ngày chuyển tiếp liên tục; chọn **k = 4** vì cho các cụm có ý nghĩa thực tế:

Cụm	Kiểu ngày	Đặc điểm
0 (443 ngày)	**Tải thấp**	Gần phẳng, ≈ 16 kWh/ngày; **75% số ngày mùa hè** (đi vắng, không sưởi)
1 (432 ngày)	**Ngày đi làm**	Đỉnh sáng 7–8h và **tối 20h (2,5 kW)**; chỉ 9% là cuối tuần
2 (350 ngày)	**Ở nhà ban ngày**	Tải đều 1,5–1,8 kW từ 7h–21h; 40% là cuối tuần
3 (192 ngày)	**Tải cao**	Đỉnh 19h 3,3 kW, ≈ 42 kWh/ngày; 61% cuối tuần, chủ yếu mùa đông

K-Means tự tìm ra lịch sinh hoạt (ngày thường / cuối tuần) và theo mùa dù đầu vào chỉ có 24 giá trị công suất.

4. Kết luận

Dataset	KNN	Naive Bayes	Decision Tree	K-Means
#697 Dropout (Acc / macro-F1)	0,720 / 0,621	0,689 / 0,614	**0,745 / 0,655**	k=3; tìm ra cụm 82% Dropout; ARI 0,145
#235 Điện năng (Acc / macro-F1)	0,635 / 0,642	0,572 / 0,575	**0,668 / 0,675**	k=4; 4 kiểu ngày tiêu thụ điện

1. **Thống kê mô tả** định hướng cách làm: lệch lớp → dùng macro-F1; đa cộng tuyến và rò rỉ (Global_intensity) → loại biến; tính chu kỳ → đặc trưng thời gian và chia theo thời gian.
2. **Decision Tree** tốt nhất trên cả hai dataset nhờ học được quan hệ phi tuyến và cho luật dễ giải thích; **KNN** đứng thứ hai, cần chuẩn hóa và chọn k; **Naive Bayes** nhanh nhất nhưng kém nhất do giả định độc lập và phân phối chuẩn bị vi phạm.
3. **K-Means** hữu ích để khám phá nhóm (sinh viên thất bại học tập, kiểu ngày tiêu thụ) nhưng không thay thế được phân lớp; chọn k cần kết hợp Elbow, Silhouette và ý nghĩa thực tế.
4. **Hạn chế:** lớp Enrolled và lớp Trung bình còn yếu → có thể thử cân bằng lớp (`class_weight` , SMOTE) hoặc mô hình ensemble.

Tài liệu tham khảo: UCI Machine Learning Repository – dataset #697 (DOI 10.24432/C5MC89) và #235 (DOI 10.24432/C58K54); Martins et al. (2021), *Early prediction of student's performance in higher education*, Springer; scikit-learn documentation (scikit-learn.org).